

APRENDIZAJE SUPERVISADO

Fran Llaneza

Proyecto final de asignatura

Microsoft Malware Prediction – Introducción





Overview | Data | Code | Discussion | Leaderboard | Rules — Join Competition

Data Description

The goal of this competition is to predict a Windows machine's probability of getting infected by various families of malware, based on different properties of that machine. The telemetry data containing these properties and the machine infections was generated by combining heartbeat and threat reports collected by Microsoft's endpoint protection solution, Windows Defender.

Each row in this dataset corresponds to a machine, uniquely identified by a `MachineIdentifier`. `HasDetections` is the ground truth and indicates that Malware was detected on the machine. Using the information and labels in `train.csv`, you must predict the value for `HasDetections` for each machine in `test.csv`.

https://www.kaggle.com/c/microsoft-malware-prediction/data

Microsoft Malware Prediction – Problema



CONJUNTO DE DATOS

El conjunto de datos corresponde a la competición de Kaggle **Microsoft Malware Prediction** y puede descargarse desde el siguiente enlace (el fichero “train.csv”):

https://www.kaggle.com/competitions/microsoft-malware-prediction/data

Cada fila del dataset corresponde a una única máquina, identificada por el campo MachineIdentifier. El target es la variable HasDetections, que indica si se ha detectado la infección de la máquina por el malware.

OBJETIVO

Desarrollar un proyecto de modelización supervisada para predecir la probabilidad de infección de un ordenador con Windows. El trabajo debe incluir todas las etapas contempladas en la checklist de ML vista en la primera sesión: entendimiento de los datos, preparación de los datos, modelización y evaluación. El código, en formato Notebook, tendrá que estar correctamente organizado y comentado para facilitar su comprensión, y deberá poder ejecutarse sin errores. No hay restricciones en cuanto al uso de las técnicas y algoritmos supervisados que se consideren.

Microsoft Malware Prediction – Evaluación



ENTREGA

- Fecha límite: **7 Julio 2026, 23:59pm**
- Formato: Jupyter Notebook (formato .ipynb)
- Nombre: 0726_MLSup_Nombre_Apellido
- Subida a campus virtual

ASPECTOS A EVALUAR

CONCEPTOS DE ML

- Identificación de la tarea correcta
- Utilizar las métricas de validación adecuadas
- Partición adecuada de los datos
- Elegir el/los algoritmos adecuados para la tarea identificada
- Transformación de las variables
- Imputación correcta de los nulos
- Interpretación de resultados y conclusiones del modelo

EFICIENCIA DE CÓDIGO

- Encapsulamiento de los procesos en funciones para evitar duplicación de código
- Priorizar las *list comprehension* y los métodos *apply* y *map* como alternativas a los bucles

INTERPRETACIÓN DE RESULTADOS

- Usar distintos tipos de gráficos para explorar los datos durante la fase de análisis descriptivo
- Interpretación del modelo más allá de las métricas de validación / test: importancia de variables, dibujo del árbol, etc


¡SUERTE!